PROGRAMA DE PÓS-GRADUAÇÃO EM

Biologia Vegetal

Universidade Federal de Pernambuco

Análise de mapas de Hi-C

Amanda Souza Câmara

Leibniz Institute of Plant Genetics and Crop Plant Research



26 de outubro de 2026

In Silico Genebank Proteomics

IPK LEIBNIZ-INSTITUT

O que queremos saber

- Qualidade
- Probabilidade de contato
- Compartimentos
- Domínios de associação topológica (topologically associating domains, TADs)
- Loops

nature communications

Article | Open access | Published: 20 April 2020

Heat stress-induced transposon activation correlates with 3D chromatin organization rearrangement in *Arabidopsis*

Linhua Sun, Yuqing Jing, Xinyu Liu, Qi Li, Zhihui Xue, Zhukuan Cheng, Daowen Wang, Hang He ✉ & Weiqiang Qian ✉

Nature Communications **11**, Article number: 1886 (2020) | Cite this article

Para produzir as estatísticas dos reads

- Bash script no github
- Usa samtools
- Na sua pasta do curso:
- mkdir hic_analyses_scripts

- bash ../ hic_analyses_scripts/hic_bam_summary.sh aligned/merged_dedup.bam Arabidopsis_test

- Comparar com o primeiro exemplo de Arabidopsis

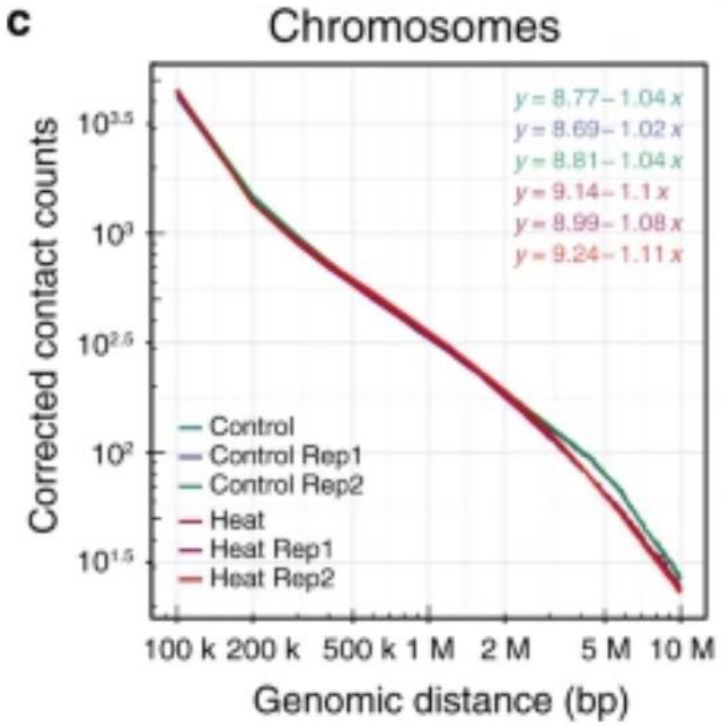
Column	Meaning
sample	Sample name supplied when running the script.
bam_pairs	Number of complete primary read pairs represented in merged_dedup.bam. This is not the original number of raw FASTQ pairs.
duplicate_pairs	Number of read pairs for which at least one mate has the BAM duplicate flag (0x400).
duplicate_fraction	duplicate_pairs / bam_pairs. Fraction of pairs in the BAM marked as duplicates.
both_mapped_pairs	Number of pairs for which both mates mapped to the reference. Includes duplicates and pairs with low MAPQ.
singleton_pairs	Number of pairs for which exactly one mate mapped.
singleton_fraction	singleton_pairs / bam_pairs. Fraction of pairs with only one mapped mate.
non_dup_q10	Number of pairs passing those filters.
p_non_dup_q10	non_dup_q10 / bam_pairs. Fraction of BAM pairs retained after these filters.
pairs_ge_1kb	Number of filtered pairs that are either interchromosomal or map at least 1 kb apart on the same chromosome.
p_ge_1kb	pairs_ge_1kb / non_dup_q10. Fraction of filtered pairs meeting the ≥1-kb definition.
pairs_ge_1mb	Number of filtered pairs mapping to the same chromosome at least 1 Mb apart.
p_ge_1mb_among_ge_1kb	pairs_ge_1mb / pairs_ge_1kb. Fraction of the ≥1-kb group that is intrachromosomal and separated by at least 1 Mb.
interchromosomal	Number of filtered pairs whose mates map to different chromosomes.
p_interchromosomal_among_ge_1kb	interchromosomal / pairs_ge_1kb. Fraction of the ≥1-kb group that is interchromosomal.

*Feito com IA

Probabilidade de contato

- java -jar ../myjuicer/scripts/common/juicer_tools.jar dump expected NONE inter.hic chr1 BP 100000 > expected_chr1_100kb.txt
- python3 ../HiC_scripts/plot_hic_decay_random_coil.py --plot-random-coil -avn sun_arabidopsis_control/sun_arabidopsis_control_expected_chr1_100kb.txt -avn sun_arabidopsis_heat/expected_chr1_100kb.txt

Encontrado no estudo original



Compartimentos

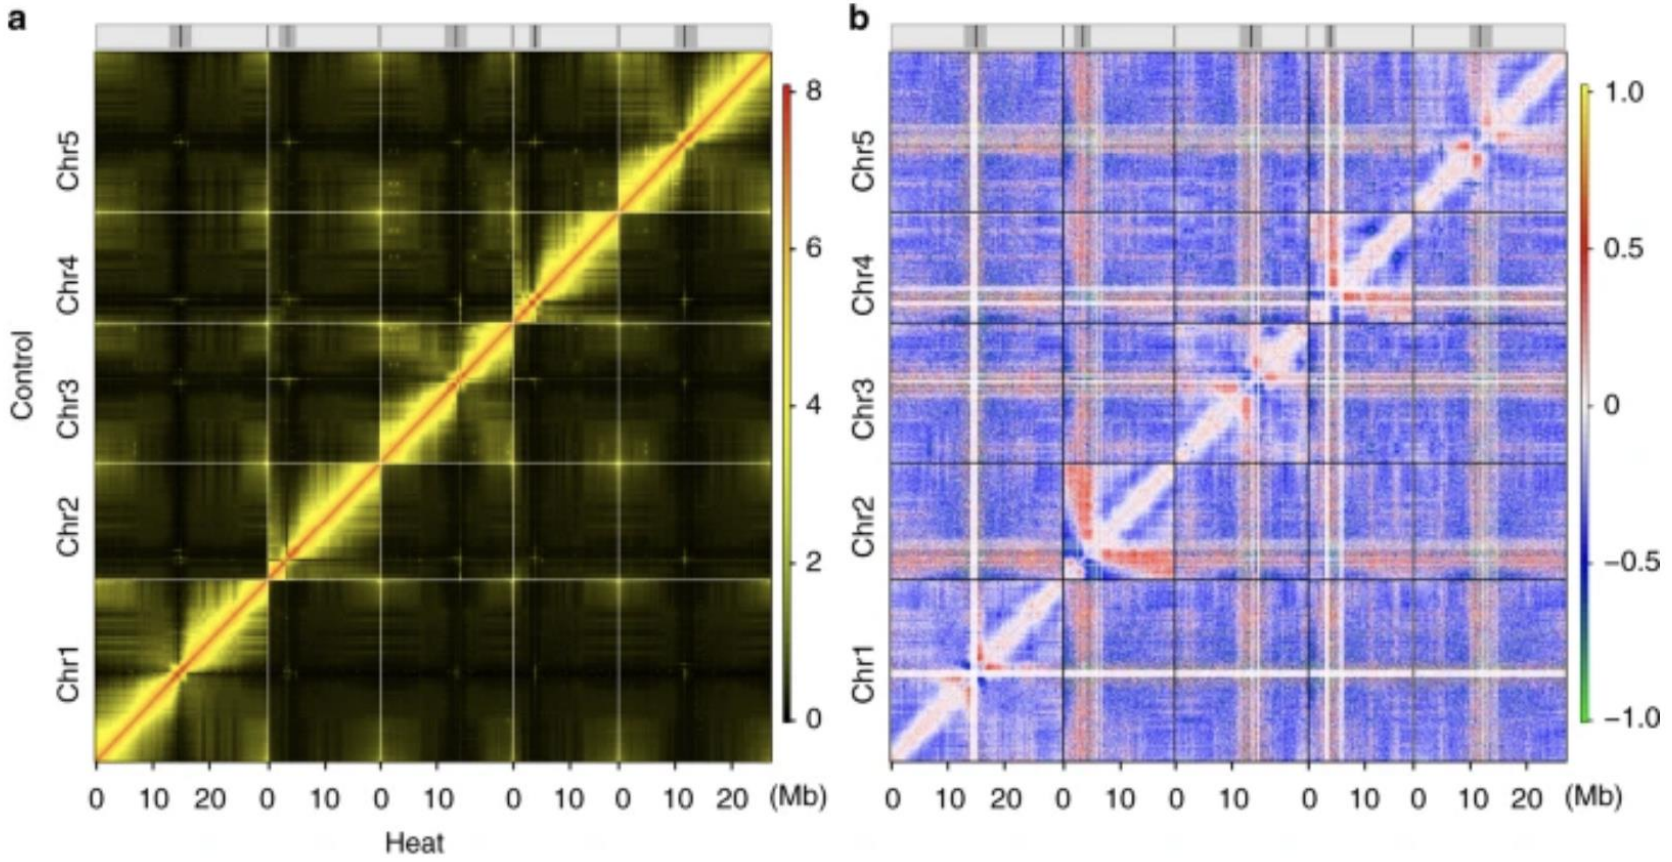
- Padrão xadrez de regiões que interagem com mais frequência entre si – como destacar essa padrão
  - No juicebox – expected mostra a média de contatos por distância genômica
  - Por que log(observed/expected) gera valores negativos e positivos, azuis e vermelhos?

  - Coeficiente da correlação de Pearson, indica quão semelhantes são duas regiões em relação às demais

  - A decomposição da matriz de correlação, encontra direções num espaço multidimensional em que a variância dos dados originais seja máxima. Essas direções,
    autovetores, permitem resumir os principais padrões de variação dos dados ori
    ginais.

Abrir um inter.hic como control

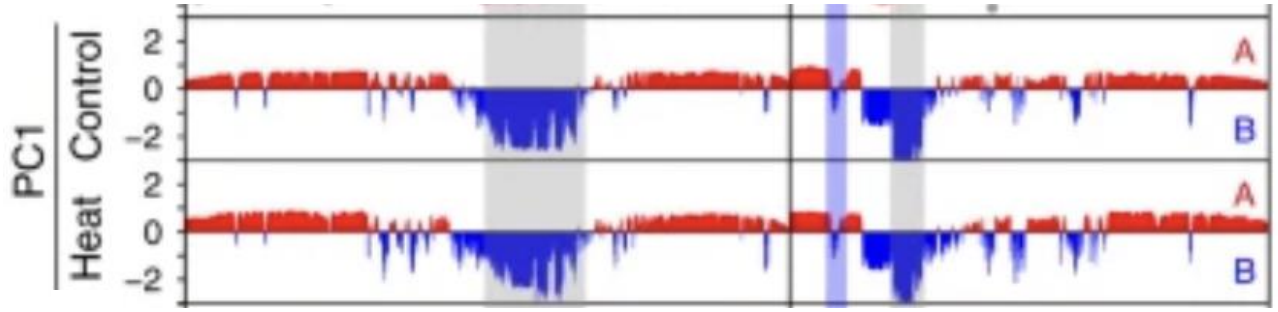
- Como no artigo original



Extrair autovetores

- java -Xmx8g -jar ../myjuicer/scripts/common/juicer_tools.jar pearsons -p KR inter.hic chr1 BP 100000 sun_arabidopsis_pearsons_chr1_100kb.txt
- python3 ../../HiC_scripts/calculate_pc.py sun_arabidopsis_pearsons_chr1_100kb.txt --pc 3 --output chr1_PC3_100kb.txt --eigenvalues chr1_eigenvalues.tsv
- python3 ../../HiC_scripts/plot_eigenvector_pc.py chr1_PC1_100kb.txt --component 1 --chromosome chr1 --bin-size 100000 --output chr1_PC1.pdf --png chr1_PC1.png --no-show

No artigo original



TADs

- Quadrados ao longo da diagonal de regiões com mais contatos lodais entre si
- java -Xmx16g -jar ../myjuicer/scripts/common/juicer_tools.jar arrowhead -r 10000 -k KR --threads 8 --ignore_sparsity inter.hic sun_arabidopsis_heat_contact_domains
- (se faltarem norms: java -Xmx16g -jar myjuicer/scripts/common/juicer_tools.jar addNorm inter.hic)
- (se a matriz for muito esparsa, poucos pares de reads: --ignore_sparsity)
- No juicebox, com inter.hic aberto,abrir *2d annotations, add local* sun_arabidopsis_heat *_contact_domains/10000_blocks.bedpe*

Arrowhead — TAD-like contact domains

*Feito com IA

Parameter	What it controls	Default / guidance
-r	Resolution of the contact matrix	10000 (10 kb) for medium-resolution maps; 5000 for higher r esolution
-k	Matrix normalization	KR is generally preferred when av ailable; alternatives are VC, VC_S QRT, and NONE
-m	Size of the sliding window used to find domains	2000; must be an even number
-c	Chromosome(s) to analyze	All chromosomes by default; e.g. -c chr1
--threads	Number of CPU threads	Defaults to 1 in documented versi ons; 0 uses available threads
--ignore_sparsity	Bypasses the preliminary sparsity check	Does not improve data quality or guarantee loop calls

10000_blocks.bedpe

*Feito com IA

Coluna	Nome do campo	Significado
1	chr1	Cromossomo associado à primeira dimensão do domínio.
2	x1	Coordenada inicial do domínio na primeira dimensão, em bp.
3	x2	Coordenada final do domínio na primeira dimensão, em bp.
4	chr2	Cromossomo associado à segunda dimensão. Para domínios cis, geralmente é o mesmo cromossomo de chr1.
5	y1	Coordenada inicial na segunda dimensão, em bp.
6	y2	Coordenada final na segunda dimensão, em bp.
7	name	Nome ou identificador da anotação; normalmente ..
8	score	Campo genérico do formato BEDPE; geralmente não contém o escore específico do Arrowhead.
9	strand1	Orientação da primeira dimensão; normalmente ..
10	strand2	Orientação da segunda dimensão; normalmente ..
11	color	Cor da anotação ao ser exibida no Juicebox.
12	score	Escore específico do Arrowhead associado ao canto do domínio; valores maiores indicam maior evidência de um canto de domínio segundo esse escore.
13	uVarScore	Variância dos valores na parte triangular superior do domínio.
14	lVarScore	Variância dos valores na parte triangular inferior do domínio.
15	upSign	Negativo da soma dos sinais dos valores na parte triangular superior.
16	loSign	Soma dos sinais dos valores na parte triangular inferior.

TAD-separation score

- python3 ../../HiC_scripts/calculate_tad_separation_juicer_v2.py inter.hic --juicer-jar ../myjuicer/scripts/common/juicer_tools.jar --chromosome chr1 --resolution 10000 --out-prefix sun_arabidopsis_chr1_10kb

- a média dos z-scores dos contatos entre janelas à esquerda e à direita de cada posição.
- O z-score indica quantos desvios-padrão um valor está acima ou abaixo da média. É uma maneira de saber se uma observação é alta ou baixa em relação ao que seria esperado, $z = \frac{x-\mu}{\sigma}$.

Loops

- Pontos (peaks) fora da diagonal
- java -Xmx16g -jar ../myjuicer/scripts/common/juicer_tools.jar hiccups --cpu -r 10000 -k KR inter.hic sun_arabidopsis_heat_loops
- No juicebox, com inter.hic aberto,abrir *2d annotations, add local* sun_arabidopsis_heat *_loops/merged_loops.bedpe*

HiCCUPS — loop calling

*Feito com IA

Parameter	What it controls	Typical 10-kb setting
-r	Resolution(s) used for loop calling	10000
-k	Matrix normalization	KR, when available
-f	FDR threshold	0.1 = 10%
-p	Peak width used to identify enriched pixels	2
-i	Width of the local comparison window	5
-d	Distance used to merge nearby enriched pixels into loop calls	20000 bp
-t	Four thresholds used to combine loop evidence from different filters	0.02,1.5,1.75,2
-m	Matrix size used for the analysis	Default 512
-c	Chromosome(s) to analyze	All chromosomes by default
--threads	Number of CPU threads	Defaults to 1 in documented versions
--cpu	Uses the CPU implementation instead of GPU/CUDA	Required for your Mac's CPU run
--ignore_sparsity	Bypasses the preliminary sparsity check	Does not improve data quality or guarantee loop calls

merged_loops.bedpe

*Feito com IA

Coluna	Nome do campo	Significado
1	chr1 / chromosome1	Cromossomo da primeira âncora.
2	x1	Coordenada inicial da primeira âncora, em pares de bases (bp).
3	x2	Coordenada final da primeira âncora, em bp.
4	chr2 / chromosome2	Cromossomo da segunda âncora.
5	y1	Coordenada inicial da segunda âncora, em bp.
6	y2	Coordenada final da segunda âncora, em bp.
7	name	Identificador textual do loop, quando presente; pode ser ..
8	score	Campo genérico do formato BEDPE; pode ser apenas um marcador sem valor informativo.
9	strand1	Orientação associada à primeira âncora; geralmente . para loops Hi-C.
10	strand2	Orientação associada à segunda âncora; geralmente ..
11	color	Cor usada para exibir a anotação no Juicebox.
12	observed	Contagem observada de contatos no pixel central do loop.
13	expected_bottom_left	Contagem esperada estimada usando o fundo inferior esquerdo (bottom-left).
14	expected_donut	Contagem esperada estimada usando a vizinhança em forma de anel (donut).
15	expected_horizontal	Contagem esperada segundo o fundo horizontal.
16	expected_vertical	Contagem esperada segundo o fundo vertical.
17	fdr_bottom_left	Valor de q/FDR calculado com o modelo de fundo inferior esquerdo.
18	fdr_donut	Valor de q/FDR calculado com o modelo donut.
19	fdr_horizontal	Valor de q/FDR calculado com o modelo horizontal.
20	fdr_vertical	Valor de q/FDR calculado com o modelo vertical.
21	number_collapsed / numCollapsed	Número de pixels agrupados para formar a chamada do loop.
22	centroid1	Coordenada da primeira âncora correspondente ao centro do agrupamento de pixels.
23	centroid2	Coordenada da segunda âncora correspondente ao centro do agrupamento.
24	radius	Raio do agrupamento no espaço da matriz.

Resumo de loops e TADS

- python3 ../../HiC_scripts/summarize_hic_features.py --loops sun_arabidopsis_control_loops/merged_loops.bedpe --tads sun_arabidopsis_control_contact_domains/10000_blocks.bedpe